RELATÓRIO TÉCNICO DESCRITIVO

Competição Kaggle

a. Nomes dos integrantes

- Antonio Camilo Santos Feitosa
- Fabricia Karollyne Santos Resende

b. Explicação clara do problema tratado e link para a página da competição no Kaggle

Nesta competição do Kaggle, a ideia é usar dados de sensores de um dispositivo usado no pulso (tipo um relógio) para diferenciar movimentos do dia a dia de comportamentos repetitivos focados no corpo (BFRBs), como puxar cabelo, roer unhas ou cutucar a pele. Em outras palavras, o desafio é fazer um modelo que consiga perceber padrões nesses sinais e dizer se o movimento parece um gesto comum (como ajustar os óculos ou beber água) ou um gesto do tipo BFRB - Body-Focused Repetitive Behaviors. Além disso, quando for BFRB, o modelo também precisa identificar qual gesto específico está acontecendo.

Os dados vêm de diferentes sensores do dispositivo. Além do sensor de movimento (IMU), existem sensores que ajudam a perceber o calor do corpo (termopilhas) e proximidade (time-of-flight). Um ponto importante é que, na avaliação, parte do conjunto de teste tem somente IMU - Inertial Measurement Unit e outra parte tem todos os sensores, o que ajuda a medir se esses sensores extras realmente melhoram a detecção dos comportamentos.

Link da competição:

https://www.kaggle.com/competitions/cmi-detect-behavior-with-sensor-data

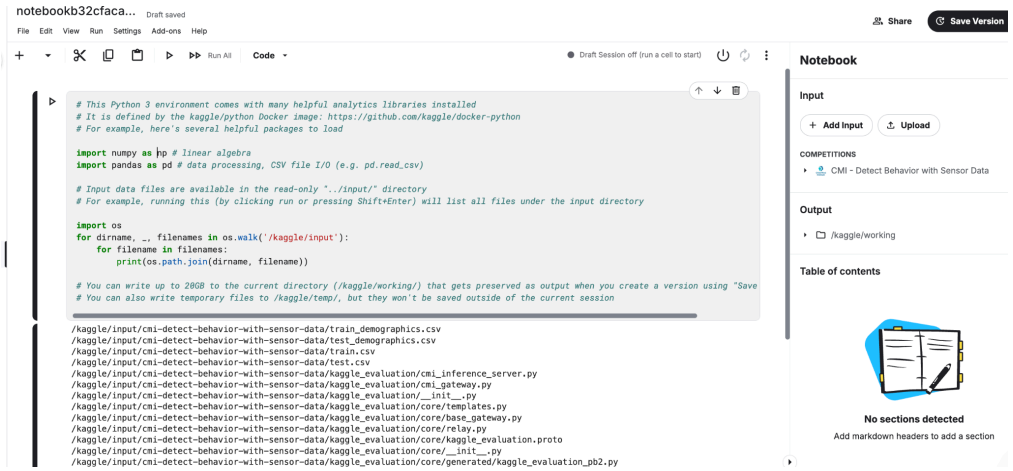

c. Análise exploratória de dados realizada

Passando para a etapa de Análise Exploratória de Dados, é importante ressaltar que ela contou com o auxílio das informações disponibilizadas no próprio Kaggle pela equipe vencedora da competição. Essas informações incluíram sugestões de pré-processamento e feature engineering. No entanto, houve a necessidade de realizar etapas adicionais de pré-processamento, como a aplicação de PCA para redução da dimensionalidade de alguns conjuntos de dados, além da seleção de características consideradas mais representativas dos movimentos capturados pelos sensores.

O processo iniciou com o carregamento dos dados de treinamento e teste disponibilizados pela competição no Kaggle. Os arquivos, em formato CSV, continham sequências de dados capturados por múltiplos sensores, organizadas por identificadores únicos de sequência e de sujeito. A primeira filtragem removeu a sequência identificada como SEQ_011975, registrada sem qualquer gesto associado e que, portanto, não contribuiria para o treinamento do modelo. Em seguida, aplicou-se um filtro baseado na proporção de amostras gestuais dentro de cada sequência. Foram mantidas apenas aquelas em que pelo menos 20% das amostras continham um gesto válido. Essa estratégia eliminou sequências muito curtas ou com predominância de períodos de inatividade, direcionando o modelo para padrões comportamentais mais relevantes.

Na sequência, realizou-se o processamento específico dos diferentes tipos de sensores. Nos dados de profundidade TOF, o valor -1 indicava ausência de leitura ou distâncias muito elevadas; esses valores foram substituídos por 500, mantendo a coerência numérica enquanto representavam uma medição extrema. O tratamento de valores ausentes seguiu uma abordagem sequencial aplicada a todas as colunas numéricas. Inicialmente, utilizou-se a técnica forward fill para propagar o último valor válido ao longo da sequência temporal. Posteriormente, aplicou-se backward fill para preencher lacunas remanescentes no início das sequências. Por fim, quaisquer valores ainda ausentes foram preenchidos com zero, garantindo a integridade do conjunto de dados ao longo de todo o pipeline.

Um desafio importante em dados sequenciais é a variabilidade no comprimento das sequências capturadas. Para uniformizar os dados de entrada do modelo de machine learning, implementou-se uma padronização baseada no percentil 94 da distribuição dos comprimentos, resultando em aproximadamente 120 amostras por sequência. Sequências que excediam esse limite foram truncadas, mantendo-se apenas as primeiras 120 amostras, enquanto sequências mais curtas foram preenchidas pela repetição da última amostra disponível até atingir o comprimento-alvo. Essa padronização garantiu dimensionalidade uniforme, requisito essencial para o processamento em lote por modelos de ensemble.

Na parte de engenharia de atributos, utilizou-se os dados brutos do acelerômetro nos três eixos (acc_x, acc_y, acc_z), foram derivadas diversas representações. Inicialmente, calculou-se a magnitude da aceleração, capturando a intensidade total do movimento independentemente da direção. Em seguida, realizou-se a remoção do componente gravitacional utilizando os dados de orientação em formato quaternion fornecidos pelo giroscópio. Aplicou-se uma rotação inversa ao vetor constante da gravidade terrestre (0, 0, -9.81 m/s²), projetando-o no sistema de coordenadas do dispositivo e

subtraindo-o dos valores brutos de aceleração. Dessa forma, obtiveram-se acelerações ajustadas (acc_x2, acc_y2, acc_z2), representando o movimento puro do usuário, sem interferência do sinal gravitacional. Para capturar características dinâmicas, calcularam-se as derivadas temporais dos sinais de aceleração. O jerk, definido como a taxa de variação da aceleração ao longo do tempo, foi obtido para cada eixo por meio de diferenciação numérica, bem como sua magnitude combinada. Também foi calculada a derivada temporal da magnitude da aceleração, resultando na métrica acc_mag_jerk. Essas variáveis permitem identificar transições rápidas nos padrões de movimento, frequentemente determinantes na diferenciação entre gestos. As mesmas operações foram aplicadas às acelerações ajustadas pela gravidade, formando um conjunto paralelo de atributos dinâmicos.

Complementarmente, foram calculadas correlações móveis entre pares de eixos de aceleração em janelas temporais de cinco amostras. As correlações de Pearson entre acc_x e acc_y, acc_x e acc_z, e acc_y e acc_z capturaram o grau de sincronização entre movimentos nos diferentes eixos, padrão que varia conforme o gesto executado. Esses cálculos também foram replicados para os dados sem o componente gravitacional. No que se refere aos dados giroscópicos, representados em formato quaternion (rot_w, rot_x, rot_y, rot_z), extraiu-se o ângulo de rotação por meio da expressão 2 × arccos(rot_w), obtendo-se a magnitude angular em radianos. A velocidade angular foi derivada como a variação temporal desse ângulo. Além disso, consideraram-se as velocidades angulares nos três eixos, seja diretamente fornecidas pelo sensor, seja obtidas por diferenciação dos componentes do quaternion. A magnitude combinada da velocidade angular representou a intensidade total da rotação, enquanto a distância angular capturou mudanças incrementais na orientação ao longo do tempo.

Após a conclusão da engenharia de atributos, o conjunto de dados processado foi reorganizado em formato tabular, no qual cada linha representava uma amostra temporal de uma sequência padronizada e cada coluna correspondia a uma característica derivada. Valores ausentes residuais foram novamente preenchidos com zero. O mesmo pipeline foi aplicado ao conjunto de teste, garantindo consistência entre treinamento e inferência.

d. Explicação do algoritmo/modelo de Aprendizado de Máquina escolhido (ou ensemble de modelos) e justificativa da escolha

O modelo escolhido para a implementação foi o Random Forest. Trata-se de um modelo ensemble que constrói várias árvores de decisão de forma independente e combina os resultados por votação. Na prática, isso ajuda a capturar relações não lineares entre as variáveis sem precisar de uma modelagem muito complexa.

A escolha foi intencionalmente mais simples. Como a base de dados é grande e já passou por um bom pré-processamento e por engenharia de features, não havia necessidade de utilizar um modelo mais sofisticado. As 35 features extraídas da IMU, como magnitudes, derivadas temporais, correlações e diferentes transformações dos sinais, já carregam bastante informação relevante sobre os padrões de movimento. Além disso, por se tratar de um conjunto de dados amplo, o Random Forest se mostrou interessante por ser naturalmente mais estável e menos propenso a sobreajuste quando comparado a modelos baseados em boosting, como o XGBoost. Enquanto algoritmos de boosting podem ajustar excessivamente os dados caso não sejam bem regularizados, o Random Forest tende a manter um comportamento mais equilibrado, já que as árvores são treinadas de forma independente e com amostragem aleatória.

No projeto em questão, foi implementada uma estratégia de validação cruzada e otimização de hiperparâmetros utilizando GridSearchCV. O algoritmo de busca em grid testou 216 combinações diferentes de hiperparâmetros (3×4×3×4×2), cada uma validada com k-fold=5, totalizando 1.080 iterações de treinamento em 5 subconjuntos diferentes. Os melhores hiperparâmetros encontrados foram:

- n_estimators: 150 - O modelo usa 150 árvores de decisão em vez das 100 iniciais, aumentando a capacidade de aprendizado
- max_depth: 12 - Profundidade máxima de 12 níveis (mais profundo que os 10 iniciais), permitindo capturar relações mais complexas
- min_samples_split: 5 - Exige mínimo 5 amostras para dividir um nó, reduzindo ruído
- min_samples_leaf: 2 - Cada folha contém mínimo 2 amostras, equilibrando complexidade e regularização
- max_features: 'sqrt' - Usa raiz quadrada do número total de features em cada split, aumentando diversidade das árvores

Nesse sentido, em cada iteração, 4 partes são usadas para treino e 1 parte é usada para validação, alternando qual fold serve como validação. Isso garante que todos os dados sejam utilizados tanto para treino quanto para validação, reduzindo a variância do desempenho estimado e evitando que o resultado dependa de uma única divisão treino-teste, que poderia ser enviesada.

e. Relato sobre a implementação e sobre a experiência de submissões e participação no leaderboard do Kaggle

Esta foi a primeira implementação de um sistema na plataforma Kaggle. A dificuldade inicial foi entender como acessar e manipular os dados disponibilizados na própria competição. No começo, houve certa limitação por não conseguir realizar o download direto para o computador, o que levou à necessidade de trabalhar diretamente nos notebooks da plataforma. Aos poucos, foi possível compreender o funcionamento do ambiente, testar códigos nas células e estruturar a solução de forma incremental.

Após entender melhor a dinâmica da plataforma, a base de dados foi analisada com mais profundidade. Foram realizados testes de processamento e tratamento dos dados com base no conhecimento prévio sobre análise e preparação de dados. Em paralelo, também foi feito um estudo das soluções publicadas, principalmente das equipes vencedoras, buscando entender quais estratégias de engenharia de características, pré-processamento e modelagem estavam sendo utilizadas.

A partir dessa análise, optou-se por seguir uma abordagem própria. Em vez de replicar exatamente os métodos mais complexos utilizados pelos primeiros colocados, a proposta foi utilizar um modelo mais simples e concentrar maior esforço na etapa de pré-processamento e engenharia de features. Isso exigiu adaptações específicas, como técnicas adicionais para redução de dimensionalidade e organização dos dados, de acordo com o modelo escolhido. O objetivo foi avaliar até que ponto um pipeline bem estruturado poderia alcançar resultados competitivos mesmo sem recorrer às soluções mais sofisticadas.

A dinâmica de submissão na plataforma também foi uma experiência importante. O Kaggle solicita apenas o envio do arquivo com as predições, que são avaliadas automaticamente com base na métrica da competição. A cada submissão, era possível acompanhar a variação da pontuação no leaderboard, o que permitiu analisar o impacto de cada ajuste realizado no modelo ou no processamento dos dados. Toda essa experiência tornou o processo bastante iterativo. Pequenas mudanças no tratamento das features ou nos parâmetros do modelo já geravam diferenças perceptíveis na pontuação. Foi possível perceber, na prática, como decisões de pré-processamento, seleção de variáveis e organização do pipeline influenciam diretamente o desempenho final. Além disso, a participação no leaderboard trouxe uma visão mais realista sobre validação de modelos, comparação de resultados e otimização contínua.

f. Paralelo entre o problema resolvido e uma possível futura reutilização/adaptação da solução para um problema real da comunidade (UFS, Estado, Município etc.)

Um possível paralelo entre o problema resolvido na competição do Kaggle e uma aplicação real na comunidade está no monitoramento de movimentos corporais para fins de saúde e qualidade de vida. Na competição, o objetivo era identificar padrões de movimento a partir de sensores vestíveis e classificá-los como gestos comuns ou comportamentos repetitivos específicos. Essa mesma lógica pode ser aplicada em contextos reais, principalmente na área da saúde preventiva e acompanhamento físico.

Na UFS, por exemplo, o sistema poderia ser adaptado em parceria com os departamentos de Educação Física e Fisioterapia. A universidade já desenvolve iniciativas

voltadas à promoção da saúde, como o projeto Projeto Mais Viver, que atende a comunidade com atividades físicas e acompanhamento profissional. Nesse contexto, o uso de sensores semelhantes aos da competição permitiria monitorar os movimentos das participantes durante os exercícios, analisando padrões, intensidade, repetição e possíveis execuções incorretas.

O processamento de dados desenvolvido no projeto, incluindo tratamento de sinais, padronização de sequências, extração de características como magnitude, variação temporal e correlações entre eixos, poderia ser reaproveitado quase integralmente. O modelo de classificação poderia ser treinado para identificar, por exemplo, se um exercício está sendo executado corretamente, se há compensações de movimento ou até indícios de sobrecarga que possam gerar lesões. Isso ajudaria os profissionais a terem uma visão mais objetiva e contínua do desempenho dos participantes, complementando a avaliação presencial.

Além disso, essa solução poderia contribuir para o acompanhamento de idosos ou pessoas em processo de reabilitação fisioterapêutica. O sistema poderia identificar padrões de instabilidade, movimentos repetitivos prejudiciais ou evolução no controle motor ao longo do tempo. Dessa forma, o projeto deixaria de ser apenas uma análise acadêmica e passaria a ter impacto direto na comunidade atendida pela universidade.